분류 알고리즘 - 2

Kyungsik Han

Decision Tree


Decision Tree

```
from sklearn.tree import DecisionTreeClassifier
dt = DecisionTreeClassifier(criterion='entropy', max depth=3, random state=0)
dt.fit(X train std, y train)
DecisionTreeClassifier(class weight=None, criterion='entropy', max depth=3,
           max features=None, max leaf nodes=None,
           min impurity decrease=0.0, min impurity split=None,
           min samples leaf=1, min samples split=2,
           min weight fraction leaf=0.0, presort=False, random state=0,
           splitter='best')
# X 테스트 데이터의 예측값 구하기
y pred = dt.predict(X test std)
# 정답값과 예측값의 비교
accuracy score(y test, y pred)
```

0.9666666666666667


Random Forest

Random Forest



다양한 분류기가 있다고 가정

Random Forest (Ensemble)



직접 투표 분류기: 각 분류기의 예측을 모아서 가장 많이 선택된 클래스를 예측하는 것

(성능) 다수결 투표 분류기 > 개별 분류기 이는 큰 수의 법칙(law of large number) 때문.

Random Forest (Ensemble)

estimators=[('lr', log clf), ('rf', rnd clf), ('svc', svm clf)],

```
from sklearn.model_selection import train_test_split
from sklearn.datasets import make_moons

X, y = make_moons(n_samples=500, noise=0.30, random_state=42)
X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=42)

from sklearn.ensemble import RandomForestClassifier
from sklearn.ensemble import VotingClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC

log_clf = LogisticRegression(solver='liblinear', random_state=42)
rnd_clf = RandomForestClassifier(n_estimators=10, random_state=42)
svm_clf = SVC(gamma='auto', random_state=42)
```

```
from sklearn.metrics import accuracy_score

for clf in (log_clf, rnd_clf, svm_clf, voting_clf):
    clf.fit(X_train, y_train)
    y_pred = clf.predict(X_test)
    print(clf.__class__.__name__, accuracy_score(y_test, y_pred))
```

```
LogisticRegression 0.864
RandomForestClassifier 0.872
SVC 0.888
VotingClassifier 0.896
```

voting clf = VotingClassifier(

voting='hard')
voting clf.fit(X train, y train)

Ensemble 방식이 높은 성능을 보여줌

Random Forest (Ensemble)

LogisticRegression 0.864
RandomForestClassifier 0.872

VotingClassifier 0.912

SVC 0.888


```
log clf = LogisticRegression(solver='liblinear', random state=42)
rnd clf = RandomForestClassifier(n estimators=10, random state=42)
svm clf = SVC(gamma='auto', probability=True, random state=42)
voting clf = VotingClassifier(
    estimators=[('lr', log clf), ('rf', rnd clf), ('svc', svm clf)],
   voting='soft')
voting clf.fit(X_train, y_train)
VotingClassifier(estimators=[('lr', LogisticRegression(C=1.0, class weight=None, dual=False, fit intercept=True,
          intercept scaling=1, max iter=100, multi class='warn',
          n jobs=None, penalty='12', random state=42, solver='liblinear',
          tol=0.0001, verbose=0, warm start=False)), ('rf', Rando...bf',
  max iter=-1, probability=True, random state=42, shrinking=True,
  tol=0.001, verbose=False))],
        flatten transform=None, n jobs=None, voting='soft', weights=None)
from sklearn.metrics import accuracy score
for clf in (log clf, rnd clf, svm clf, voting clf):
   clf.fit(X train, y train)
   y pred = clf.predict(X test)
   print(clf. class_._ name__, accuracy_score(y_test, y_pred))
```

Soft Ensemble 방식이 Hard 보다 높은 성능을 보여줌

Begging or Pasting(Bootstrapping)

- 각기 다른 훈련 알고리즘을 사용할 수 있지만 (이전 예제 처럼),
- 같은 알고리즘을 사용하고 훈련 세트의 서브셋을 무작위로 구성하여 각기 다르게 학습 가능
 - 배깅(bagging): 훈련 세트에서 중복을 허용하여 샘플링
 - 페이스팅(pasting) or 부트스트래핑(bootstrapping): 중복을 허용하지 않고 샘플링

Begging or Pasting(Bootstrapping)



Begging or Pasting(Bootstrapping)

```
from sklearn.ensemble import BaggingClassifier

bag_clf = BaggingClassifier(
    DecisionTreeClassifier(random_state=42), n_estimators=500,
    max_samples=100, bootstrap=True, n_jobs=-1, random_state=42)
bag_clf.fit(X_train, y_train)
y_pred = bag_clf.predict(X_test)


from sklearn.metrics import accuracy_score
print(accuracy_score(y_test, y_pred))

from sklearn.ensemble import BaggingClassifier
from sklearn.ensemble import DecisionTreeClassifier
baggingClassifier
baggingClas
```

0.904

```
tree_clf = DecisionTreeClassifier(random_state=42)
tree_clf.fit(X_train, y_train)
y_pred_tree = tree_clf.predict(X_test)
print(accuracy_score(y_test, y_pred_tree))
```


0.856



kNN (k-Nearest Neighbor)

- kNN은 지금까지 논의했던 지도학습 알고리즘과 근본적으로 다름
- kNN은 Lazy Learner 기반 알고리즘
 - 훈련 데이터로부터 식별 함수를 학습하는 대신, 데이터를 기억하기 때문

- k 에 해당하는 숫자와 거리 메트릭을 선택함
- 분류하고자 하는 샘플에 대한 k개의 근접한 이웃을 찾음
- 다수결 투표 방식으로 분류 레이블을 할당함



- k를 알맞게 선택하는 것이 아주 중요
- 데이터 features 에 대한 적당한 거리 metric을 선택해야 함
- 많이 쓰는 거리 함수
 - Minkowski distance
 - Euclidean distance
 - Manhattan distance



kNN

```
# X 테스트 데이터의 예측값 구하기
y_pred = knn.predict(X_test_std)


# 정답값과 예측값의 비교
accuracy_score(y_test, y_pred)
```

1.0


kNN 평가

- 알고리즘이 간단하여 구현하기 쉬움
- 수치 기반 데이터 분류 작업에서 성능이 좋음
- 학습 데이터의 양이 많으면 분류 속도가 느려짐
- 차원(벡터)의 크기가 크면 계산량이 많아짐


Differences Among Classifiers




Logistic Regression



Decision Tree




Support Vector Machine



kNN

Look at How Each Algorithm Works



다음 영상에서 배울 내용

- 지도학습 모델 평가
 - 데이터셋
 - 평가지표 및 측정(이진분류)
 - 과적합(overfitting)
 - 오차행렬
 - 분류 평가지표
 - Accuracy, Precision, Recall, F1-score, ROC, AUC
 - 회귀 평가지표
 - R²

수고하셨습니다